CV

石禹

2023K8009926030

中国科学院大学

2025 年 12 月 19 日

目录

1 图像处理 **4**
1.1 数字图像基础 4
1.2 深度学习基础 4
1.3 图像变换 5
1.3.1 空域变换 5
1.3.2 频域变换 5
1.4 图像滤波 5
1.4.1 常见滤波器 5
1.5 形态学去噪 6
1.6 图像增强 6
1.7 基于空域的图像增强 6
1.7.1 灰度直方图 6
1.7.2 空间域滤波 7
1.7.3 空间域锐化 7
1.8 图像复原 8
1.9 图像压缩 8
1.9.1 无损压缩 8
1.9.2 有损压缩 9

2 计算机视觉 **9**
2.1 图像物体表达 9
2.2 目标检测 9
2.2.1 视频目标检测 9
2.2.2 图像目标检测 11
2.3 图像分割 12
2.4 特征提取 13
2.4.1 边缘检测 13
2.4.2 角点检测 15
2.4.3 SIFT 特征 16
2.4.4 SIFT 特征描述与匹配 16
2.4.5 鲁棒匹配（RANSAC） 16
2.5 视觉几何 17
2.5.1 相机模型 17
2.5.2 射影几何 18
2.5.3 消隐点与消隐线 19

2.5.4 单应矩阵 19
2.5.5 双目立体视觉 20
2.5.6 两视点几何 20
2.6 三维重建 21
2.6.1 相机内参数标定 21
2.6.2 视觉三维重建 22
2.6.3 视觉定位 23
2.7 目标跟踪与行为识别 25
2.7.1 目标跟踪 25
2.7.2 行为识别 27

1 图像处理

1.1 数字图像基础

图像空间分辨率

- PPI: 每英寸像素数
- 多数时候称尺寸为 M*N 的图像的空间分辨率为 M*N 像素

设备分辨率

- DPI: 每英寸点数，是打印机等设备的分辨率单位

灰度分辨率：反映图像像素灰度变化的范围（位深度为 b，则灰度级数为 2 的 b 次方）

灰度值越大，图像越亮

RGB 三通道图像可以通过运算转化为灰度图像（常用加权平均法）：

$$I = 0.3R + 0.59G + 0.11B \tag{1}$$

图像的点运算为对图像的每个像素灰度值进行数值计算。

两幅图像之间可以进行加、减、乘、除运算。

逻辑运算包括与、或、非、异或（0 为黑，1 为白）。

1.2 深度学习基础

卷积运算：

$$G(x,y) * I(x,y) = \sum_m \sum_n G(m,n) I(x-m, y-n) \tag{2}$$

其中 G 为卷积核，I 为输入图像。注意卷积运算时为将卷积核进行翻转后再进行按位相乘计算。

卷积会改变原始图像尺寸，可以在边缘补 0 来保持尺寸不变。

- 单核卷积：参数共享，对于每一层卷积层来说，所有的输出通道都使用同一个卷积核，共享同一组参数
- 多核卷积：输出的特征图通道数等于卷积核数目，每个卷积核对应一个输出通道，每个卷积核有自己的一组参数

池化：最大池化、平均池化（降采样，避免过拟合）

1.3 图像变换

1.3.1 空域变换

几何变换（欧氏、缩放、镜像、相似、仿射、射影）、灰度变换（图像增强）
在原坐标的基础上添加一个维度，变为齐次坐标：

$$\begin{bmatrix} x \\ y \end{bmatrix} \Rightarrow \begin{bmatrix} x \\ y \\ 1 \end{bmatrix} \tag{3}$$

欧氏变换为平移变换与旋转变换的组合，3 个自由度
缩放变换为各个方向的缩放，2 个自由度
相似变换为欧氏变换与等比缩放变换的组合，4 个自由度
仿射变换共 6 个自由度，可以实现平行线不变
射影变换共 8 个自由度，可以实现透视效果

1.3.2 频域变换

傅里叶变换：将图像从空间域转换到频率域
用于图像增强、去噪、压缩、特征提取、模式识别

1.4 图像滤波

相关运算：

$$G(x,y) \otimes I(x,y) = \sum_m \sum_n G(m,n) I(x+m, y+n) \tag{4}$$

与卷积的区别在于卷积需要将卷积核翻转，而相关运算不需要。
相关运算能够凸出目标图像中与模板图像相似的部分。

1.4.1 常见滤波器

高斯滤波：对邻域的像素进行加权平均，权值服从高斯分布
高斯滤波器的大小取决于标准差 ，一般取 $2 \times round_up(3\sigma) + 1$
高斯滤波在处理噪声时会模糊图像细节，尤其是边缘信息。
双边滤波：在高斯滤波的基础上，加入了灰度相似性权重，既考虑空间距离又考虑灰度差异

$$\sum_{p \in S} \exp(-\frac{|p-p_0|^2}{2\sigma_d^2}) \exp(-\frac{|I(p)-I(p_0)|^2}{2\sigma_r^2}) I(p) \tag{5}$$

频域滤波：通过傅里叶变换将图像转换到频域，进行滤波后再转换回空间域
分为低通滤波器、高通滤波器和带通滤波器

1.5 形态学去噪

定义原图像为 A，结构元素为 B

膨胀：扩大物体边界

$$A \oplus B = \{z|(B)_z \cap A \neq \emptyset\} \tag{6}$$

腐蚀：缩小物体边界

$$A \ominus B = \{z|(B)_z \subseteq A\} \tag{7}$$

膨胀与腐蚀具有对偶性：

$$(A \oplus B)^c = A^c \ominus B^s \tag{8}$$

开运算：先腐蚀后膨胀，去除小的噪声点

$$A \circ B = (A \ominus B) \oplus B \tag{9}$$

闭运算：先膨胀后腐蚀，填补小的空洞

$$A \bullet B = (A \oplus B) \ominus B \tag{10}$$

实际应用中，通常先进行开运算去除噪声点，再进行闭运算填补空洞。

1.6 图像增强

1.7 基于空域的图像增强

1.7.1 灰度直方图

表示图像灰度与该灰度值出现的频次

灰度直方图可以反映图像的亮度与对比度：亮度越高，直方图越偏右；对比度越大，直方图分布越宽。

直方图均衡化：通过调整图像灰度分布来增强图像对比度

目的：建立灰度映射，使得变换后的图像在不同灰度级上的像素数尽可能均匀分布（均匀分布熵最大，信息量最大）

令 r 和 s 分别表示**归一化**后的原图像灰度与变换后的图像灰度（$0 \leq r, s \leq 1$），变换函数为 r 的累计分布函数：

$$s = T(r) = \int_0^r p_r(w)dw \tag{11}$$

离散情况下，用频率代替概率密度函数：

$$s_k = T(r_k) = \sum_{j=0}^{k} \frac{n_j}{n} \tag{12}$$

直方图均衡化的具体步骤：

1. 统计各灰度级像素数

2. 计算原始图像直方图各灰度级的频数

3. 计算累计分布函数

4. 根据映射关系逐点修改灰度值

直方图均衡化基于全局灰度分布，可能会导致局部细节丢失。可以设计基于邻域的局部直方图均衡化方法来改善。

直方图匹配（规定化）：生成规定灰度直方图图像

直方图匹配的具体步骤：

1. 计算原始图像的均衡化映射函数 $s = T(r)$

2. 对原始图像的每个像素应用映射函数，得到均衡化图像

3. 计算规定直方图的累计分布函数 $s = G(z)$

4. 对步骤 2 得到的均衡化图像的每个像素应用反映射函数 $z = G^{-1}(s)$，得到规定直方图图像（离散情况下对于任何 s 找到对应的 z 使得 G(z) 最接近 s）

1.7.2 空间域滤波

均值滤波器：对每个像素邻域做均值运算，平滑图像，去除噪声

超限像素平滑法：对超出一定范围的像素进行平滑处理，保留边缘信息

$$g'(x,y) = \begin{cases} g(x,y) & |f(x,y) - \bar{f}(x,y)| > T \\ f(x,y) & \text{else} \end{cases} \tag{13}$$

其中 $\bar{f}(x,y)$ 为邻域均值，T 为阈值，$f(x,y)$ 为原图像像素值，$g(x,y)$ 为均值滤波后的像素值，$g'(x,y)$ 为最终输出像素值。

K 近邻均值滤波法：选择每个像素邻域中与中心像素灰度值最接近的 K 个像素进行均值运算，减少边缘模糊

最大均匀性平滑：计算环绕目标像素的最均匀区域，然后用该区域的均值替换目标像素值

中值滤波器：用领域内的中值替换目标像素值，能有效去除椒盐噪声

1.7.3 空间域锐化

对图像的边缘或轮廓进行增强，使图像更加清晰

最常用梯度锐化法（离散情况下用差分代替梯度）

使用水平、竖直或对角线梯度算子可以检测不同方向的边缘

1.8 图像复原

图像退化模型：退化系统 + 加性噪声

通常可以模型化为一个退化函数与一个加性噪声

$$n = g - Hf \tag{14}$$

无约束图像复原背景下，需要找到一个估计图像 f，使 Hf 与 g 的误差最小，即最小化下式：

$$||n||^2 = ||g - Hf||^2 \tag{15}$$

通常使用逆滤波器进行图像复原：

$$\hat{F}(u,v) = \frac{G(u,v)}{H(u,v)} \tag{16}$$

在有噪声的情况下：

$$\hat{F}(u,v) = \frac{G(u,v)}{H(u,v)} - \frac{N(u,v)}{H(u,v)} \tag{17}$$

运动模糊常用退化模型：

$$H(u,v) = \frac{T}{\pi(ua+vb)} \sin[\pi(ua+vb)] e^{-j\pi(ua+vb)} \tag{18}$$

有约束条件下可以在无约束图像复原的基础上加入约束条件，使用拉格朗日乘数法进行优化。

1.9 图像压缩

压缩率：压缩前与压缩后数据量的比值

$$CR = \frac{\text{压缩前数据量}}{\text{压缩后数据量}} \tag{19}$$

1.9.1 无损压缩

无损压缩的压缩率通常在 2-10 之间

霍夫曼编码：根据像素灰度值出现的频率分配不同长度的编码，频率高的分配短码，频率低的分配长码

使用霍夫曼树结构，每次合并最小概率子树，直到只剩下一棵树

其平均码长最短，接近香农极限（编码信息熵）

对于给定数据，霍夫曼编码可能不唯一

算术编码：将整个消息映射到 [0,1) 区间的一个子区间，通过不断细分区间来表示消息

根据每个字符的概率分布划分区间，每次选中对应字符的子区间，最终得到一个唯一的区间，选择区间内二进制表示最短的数作为编码

解码过程根据编码值逐步缩小区间，直到还原出原始消息

LZW 编码：基于字典的无损压缩方法，使用一个动态更新的字典来存储重复出现的字符串

1.9.2 有损压缩

变换编码：将图像从空间域转换到另外的正交空间（与傅里叶变换类似，对应频域）变换后的主要信息集中在少数几个系数上，其他系数可以舍弃

离散傅里叶变换（DFT）：

$$F(u,v)=\sum_{x=0}^{M-1}\sum_{y=0}^{N-1}f(x,y)e^{-j2\pi(\frac{ux}{M}+\frac{vy}{N})} \tag{20}$$

离散余弦变换（DCT）：假设目标图像为 N*N

$$F(u,v)=\alpha(u)\alpha(v)\sum_{x=0}^{N-1}\sum_{y=0}^{N-1}f(x,y)\cos[\frac{(2x+1)u\pi}{2N}]\cos[\frac{(2y+1)v\pi}{2N}] \tag{21}$$

其中

$$\alpha(u)=\begin{cases}\sqrt{\frac{1}{N}} & u=0\\ \sqrt{\frac{2}{N}} & u\neq 0\end{cases} \tag{22}$$

2 计算机视觉

2.1 图像物体表达

零样本识别：能够识别训练集中未出现过的类别

开集识别：能够对训练集中未出现过的类别进行识别和处理

2.2 目标检测

目的：在图像或视频中定位并识别目标物体的位置和类别

2.2.1 视频目标检测

背景差法：通过计算当前帧与背景模型之间的差异来检测运动目标

单高斯模型：使用单个高斯分布对背景进行建模

$$P(x)=\frac{1}{(2\pi)^{k/2}|\Sigma|^{1/2}}\exp[-\frac{1}{2}(x-\mu)^T\Sigma^{-1}(x-\mu)] \tag{23}$$

对于运动的背景，高斯模型可能无法准确建模，可以使用混合高斯模型（GMM）来处理复杂背景

$$P(x)=\sum_{i=1}^{K}w_i\cdot\mathcal{N}(x|\mu_i,\Sigma_i) \tag{24}$$

流程：

1. 设置总高斯模型数量为 K（通常为 3-7）

2. 初始化：对图像上的每个像素点，使用第一张图像的像素值作为均值，设置一个较小的方差

3. 每读入一帧图像，计算对应像素点的像素值是否与现有模型匹配（小于 2.5 个标准差），若匹配则更新参数，否则判断已有模型数是否小于 K，若小于则添加新模型，否则替换权值最小的模型。

$$\omega_{j,w,t} = (1-\alpha)\omega_{j,w,t-1} + \alpha M_{j,w,t-1} \tag{25}$$

$$\mu_{j,w,t} = (1-\rho)\mu_{j,w,t-1} + \rho z_{j,w,t} \tag{26}$$

$$\sigma^2_{j,w,t} = (1-\rho)\sigma^2_{j,w,t-1} + \rho(z_{j,w,t} - \mu_{j,w,t})^T(z_{j,w,t} - \mu_{j,w,t}) \tag{27}$$

$$\rho = \alpha N(z_{j,w,t}|\mu_{j,w,t-1}, \sigma^2_{j,w,t-1}) \tag{28}$$

4. 选择权重最大的前 B 个高斯模型作为背景模型，满足下式：

$$B = \arg\min_b (\sum_{k=1}^{b} \omega_k > \tau) \tag{29}$$

5. 对于输入的每个像素点，若与背景模型不匹配则标记为前景

光流法：通过计算图像中像素点的运动矢量来检测运动目标
光流：在连续两帧图像中由于物体运动或相机运动导致的像素移动
光流一致性假设：相邻像素点的运动是相似的

$$I(x, y, t) = I(x + \Delta x, y + \Delta y, t + \Delta t) \tag{30}$$

对变量进行泰勒展开，忽略高阶项，得到光流约束方程：

$$I_x V_x + I_y V_y + I_t = 0 \tag{31}$$

孔径问题：由于方程存在两个自由度，单个像素点的光流无法确定，需要结合邻域信息进行估计

基于梯度的方法：假设光流场局部平滑/邻域内像素具有相对的速度

- 优点：直观表述运动模式，不易受运动物体外表干扰
- 缺点：计算量大，易产生较大噪声

帧间差分法：通过计算连续两帧/多帧图像的差异来检测运动目标

- 优点：适用于动态变化的背景
- 缺点：难以检测速度过快或过慢的目标与同时存在的多个目标

2.2.2 图像目标检测

AdaBoost：通过组合多个弱分类器形成一个强分类器

Haar-like 特征：通过计算图像不同区域的灰度和后计算差值来提取特征，共有（1，2），（2，1），（3，1），（1，3），（2，2）五种类型

可以使用积分图像快速计算任意矩形区域的灰度和

$$II(x,y)=\sum_{x'\le x,y'\le y} I(x',y') \tag{32}$$

流程：

1. 初始化样本权重 $D_1=\frac{1}{N}$，N 为样本总数
2. 对于每一轮 t：选择分类正确率最低的弱分类器 h_t，计算分类错误率 ε_t，若错误率大于 0.5 则停止训练
3. 更新分类器权重：$\alpha_t=\frac{1}{2}\ln(\frac{1-\varepsilon_t}{\varepsilon_t})$
4. 更新样本权重：

$$D_{t+1}(i)=\begin{cases}\frac{D_t(i)\exp(-\alpha_t y_i)}{Z_t} & h_t(x_i)=y_i\\ \frac{D_t(i)\exp(\alpha_t y_i)}{Z_t} & h_t(x_i)\neq y_i\end{cases} \tag{33}$$

5. 所有分类器的加权组合形成最终强分类器：

$$H(x)=\text{sign}(\sum_{t=1}^{T}\alpha_t h_t(x)) \tag{34}$$

为提高检测速度与精度，最终可以级联多个强分类器，形成级联分类器。

RCNN：基于区域的卷积神经网络目标检测方法

1. 使用选择性搜索算法生成候选区域
2. 对每个候选区域进行裁剪并调整大小
3. 使用预训练的卷积神经网络提取特征
4. 使用支持向量机（SVM）对提取的特征进行分类
5. 使用边界框回归器对候选区域进行精细定位
6. 非极大值抑制（NMS）去除重叠的检测框

YOLO：单阶段目标检测方法，将目标检测任务视为一个回归问题

1. 将输入图像划分为 SxS 的网格

2. 每个网格预测 B 个边界框及其置信度分数

3. 每个网格还预测 C 个类别概率，即每张图像转化为 SxSx(B*5+C) 的输出张量

4. 结合边界框的置信度与类别概率，计算最终的检测结果

2.3 图像分割

语义分割：将图像中的每个像素分配给一个语义类别
实例分割：不仅进行语义分割，还区分同一类别的不同实例
阈值法：根据像素灰度值与设定的阈值进行分类

$$g(x,y)=\begin{cases}1 & f(x,y)>T\\ 0 & f(x,y)\le T\end{cases} \tag{35}$$

全局阈值法：复杂度低，但忽略了图像的空间信息

- P-分位数法：根据图像灰度直方图计算分位数，选择对应灰度值作为阈值
- 众数法：灰度直方图中存在多峰时，选择峰值之间的谷底作为阈值
- 迭代法：初始选择一个阈值 T，计算两部分像素的均值，更新阈值为两均值的平均值，迭代直到收敛

局部阈值法：将图像分块，分别使用全局阈值法分割，最后合并结果
局部生长法：从种子点开始，根据相似性准则将邻域像素加入区域
分水岭分割法：将图像看作地形图，通过模拟水流填充低洼区域来实现分割
均值移动法：通过迭代计算像素点在特征空间中的均值位置，实现图像分割
核心思想：找到概率密度梯度为 0 的点作为聚类中心
引入核函数 g 与带宽 h，计算每个像素点的均值位置

$$m(x)=\frac{\sum_{i=1}^{n}x_i g(\frac{||\frac{x-x_i}{h}||^2}{2})}{\sum_{i=1}^{n}g(\frac{||\frac{x-x_i}{h}||^2}{2})}-x \tag{36}$$

当 $||m(x)-x||$ 小于一个阈值时，停止迭代，否则将 x 更新为 $x+m(x)$，继续迭代
图割法：将图像分割问题转化为图的最小割问题，通过最小化能量函数实现分割
仅考虑割集的权值和最小情况下，容易出现孤立分割问题，可以引入类间相似度，使用 Normalized Cut 方法

$$Ncut(A,B)=\frac{cut(A,B)}{assoc(A,V)}+\frac{cut(A,B)}{assoc(B,V)} \tag{37}$$

其中，$cut(A,B)=\sum_{u\in A,v\in B}w(u,v)$，$assoc(A,V)=\sum_{u\in A,t\in V}w(u,t)$

类似定义总的类内相似度：

$$Nassoc(A,B)=\frac{assoc(A,A)}{assoc(A,V)}+\frac{assoc(B,B)}{assoc(B,V)} \tag{38}$$

经过推导可得：

$$Ncut(A,B)=2-Nassoc(A,B) \tag{39}$$

可见最小化类间相似度等价于最大化类内相似度，最优划分对应最小化 Ncut 值，可以通过求解广义特征值问题实现。

定义矩阵：

$$W=w(i,j),\quad D=diag(d(1),\ldots,d(n)),\quad d(i)=\sum_j w(i,j) \tag{40}$$

流程：

1. 给定点集，构建图 G=(V,E)，计算权值矩阵 W 与度矩阵 D，边权表示像素间相似度

$$w_{ij}=\begin{cases} e^{-\frac{||F(i)-F(j)||^2}{2\sigma_I^2}}\cdot e^{-\frac{||X(i)-X(j)||^2}{2\sigma_X^2}} & ||X(i)-X(j)||<r \\ 0 & \text{else} \end{cases} \tag{41}$$

2. 求解广义特征值问题 $(D-W)y=\lambda Dy$，得到特征向量

3. 选择第二小的特征值对应的特征向量，根据符号将点划分为两个子集

4. 递归对子集进行划分，直到满足停止条件

基于深度学习：

上采样：增加图像尺寸，可以使用反卷积等方法

空洞卷积：通过在卷积核中插入空洞来增加感受野

DeepLab：去除部分 Pooling 层从而保留更多空间信息，同时增加空洞卷积弥补去除 Pooling 导致的感受野减少

2.4 特征提取

2.4.1 边缘检测

边缘定义：

- 亮度突然变化的区域
- 图像灰度构成的曲面上的陡峭区域
- 灰度存在阶跃变化或屋脊状变化的区域

对目标图像先进行滤波降噪，再使用梯度算子进行边缘检测，最后进行边缘定位与连接。

常见梯度算子：

- Prewitt 算子：近似一阶微分

$$G_x = \begin{bmatrix} -1 & 0 & 1 \\ -1 & 0 & 1 \\ -1 & 0 & 1 \end{bmatrix}, \quad G_y = \begin{bmatrix} 1 & 1 & 1 \\ 0 & 0 & 0 \\ -1 & -1 & -1 \end{bmatrix} \tag{42}$$

  分别在两个方向上同时计算均值去除噪声与检测边缘

- Sobel 算子：近似一阶微分，给四邻域像素赋予更高权重

$$G_x = \begin{bmatrix} -1 & 0 & 1 \\ -2 & 0 & 2 \\ -1 & 0 & 1 \end{bmatrix}, \quad G_y = \begin{bmatrix} 1 & 2 & 1 \\ 0 & 0 & 0 \\ -1 & -2 & -1 \end{bmatrix} \tag{43}$$

- Laplacian 算子：近似二阶微分

$$\Delta I = \nabla^2 I = \frac{\partial^2 I}{\partial x^2} + \frac{\partial^2 I}{\partial y^2} \tag{44}$$

  Laplacian 算子的数字近似：

$$\begin{bmatrix} 0 & -1 & 0 \\ -1 & 4 & -1 \\ 0 & -1 & 0 \end{bmatrix} \quad \begin{bmatrix} -1 & -1 & -1 \\ -1 & 8 & -1 \\ -1 & -1 & -1 \end{bmatrix} \tag{45}$$

  运算结果为标量，丢失空间信息，二次微分对噪声敏锐（通常搭配滤波使用）

高斯拉普拉斯算子（LoG）：先进行高斯平滑，再使用 Laplacian 算子

$$LoG(x,y) = -[\frac{x^2+y^2-\sigma^2}{\sigma^4}]e^{\frac{x^2+y^2}{2\sigma^2}} \tag{46}$$

Canny 边缘检测器：加入梯度非极大值抑制与双阈值检测

流程：

1. 对原始图像进行高斯滤波降噪
2. 使用梯度算子计算图像梯度幅值与方向

$$\begin{bmatrix} -1 & 1 \\ -1 & 1 \end{bmatrix} \quad \begin{bmatrix} 1 & 1 \\ -1 & -1 \end{bmatrix} \tag{47}$$

   分别得到结果为 $D_x(x,y), D_y(x,y)$

3. 计算幅值与方向角度

$$M(x,y) = \sqrt{D_x(x,y)^2 + D_y(x,y)^2} \tag{48}$$

$$\theta(x,y) = \arctan(\frac{D_y(x,y)}{D_x(x,y)}) \tag{49}$$

M 代表梯度幅值大小，边缘处 M 增大

4. 在梯度方向上检测局部极大值，进行非极大值抑制，简化情况下使用四个方向（0°，45°，90°，135°）近似

5. 双阈值化处理：使用大阈值检测的边缘作为强边缘，小阈值检测的边缘作为弱边缘，保留与强边缘相连的弱边缘，去除孤立弱边缘

2.4.2 角点检测

Harris 角点检测：局部区域灰度变化剧烈的点

窗口平移 (u,v) 引起的灰度变化：

$$E(u,v) = \sum_{x,y} w(x,y)[I(x+u,y+v) - I(x,y)]^2 \tag{50}$$

使用泰勒展开，忽略高阶项：

$$E(u,v) \approx \sum_{x,y} w(x,y)[I_x(x,y)u + I_y(x,y)v]^2 = \sum_{x,y} w(x,y) \begin{bmatrix} u & v \end{bmatrix} \begin{bmatrix} I_x^2 & I_xI_y \\ I_xI_y & I_y^2 \end{bmatrix} \begin{bmatrix} u \\ v \end{bmatrix} \tag{51}$$

$$M = \sum_{x,y} w(x,y) \begin{bmatrix} I_x^2 & I_xI_y \\ I_xI_y & I_y^2 \end{bmatrix} \tag{52}$$

计算图像梯度可以得到 M，计算 M 的特征值 λ_1, λ_2，根据特征值大小判断角点、边缘与平坦区域：

- 角点：λ_1 与 λ_2 均较大
- 边缘：$\lambda_1 \gg \lambda_2$ 或 $\lambda_2 \gg \lambda_1$
- 平坦区域：λ_1 与 λ_2 均较小

定义角点检测函数：

$$R = det(M) - k(trace(M))^2 = \lambda_1\lambda_2 - k(\lambda_1 + \lambda_2)^2 \tag{53}$$

通常设置 k 在 0.04-0.06 之间，R 值大于某个阈值且为局部极大值时，判定为角点。

Harris 角点检测对旋转不变，对灰度仿射变换具有部分不变性，但对几何尺度变化不变性较差。

2.4.3 SIFT 特征

尺度空间：定义一系列方差不同的高斯滤波器，对图像进行多次平滑，得到不同尺度下的图像表示

$$L(x, y, \sigma) = G(x, y, \sigma) * I(x, y) \tag{54}$$

当尺度参数 σ 连续变化时，$L(x, y, \sigma)$ 构成尺度空间

高斯差分尺度空间（DoG）：通过尺度空间中相邻两个尺度图像的差分近似 Laplacian 算子

$$D(x, y, \sigma) = L(x, y, k\sigma) - L(x, y, \sigma) \tag{55}$$

通过不断增大尺度参数 σ，每层卷积得到的图像尺度逐渐缩小，得到多层 DoG 金字塔

在三维尺度空间 $D(x, y, \sigma)$ 中，搜索每个像素点的极值点，保存为候选关键点。

由于离散采样得到的极值点可能不准确，需要对候选关键点进行精确定位，对 DoG 函数进行曲线拟合，计算精细偏移量，若偏移量中任意分量大于 0.5 则移动到相邻像素点重新计算，直到收敛。

同时去除低对比度点与边缘响应点（使用 Hessian 矩阵的特征值比值进行判断，可以通过计算 trace 与 determinant 避免直接计算特征值，减少计算量）。

2.4.4 SIFT 特征描述与匹配

主方向计算：将 360 度划分为 8 个方向区间，计算关键点邻域内每个像素的梯度幅值与方向（公式 48.49），构建方向直方图，选择峰值作为主方向。

SIFT 描述子构建：将关键点邻域划分为 4x4 个子区域，每个子区域计算 8 个方向的梯度直方图，得到 128 维描述子。

为适应复杂光照变化，将 128 维描述子归一化（适应线性光照环境），将大于 0.2 的分量截断为 0.2 后再次归一化（适应非线性光照环境）。

特征匹配：

匹配准则（NNDR）：计算每个特征点与其他特征点的欧氏距离，选择距离最近的点作为匹配点，若最近距离与次近距离之比小于某个阈值（通常取 0.8），则认为匹配成功。

搜索策略（BBF）：使用 k-d 树对特征点进行组织，快速搜索最近邻点，减少计算量。

2.4.5 鲁棒匹配（RANSAC）

去除外点对匹配结果的影响

1. 确定求解模型 M，以及求解所需的最小数据点数 n，记 n 个数据点为一个样本
2. 从数据集中随机抽样一个样本，基于样本计算模型 M 的一个实例，确定实例的一致集（距离小于阈值 t 的数据点集）

3. 若一致集点数大于阈值 T，则用一致集重新估计模型 M，计算该模型的误差，并保存该模型；否则返回步骤 2

4. 经过最大迭代次数 K 后，选择最大的一致集估计模型 M 作为最终结果

2.5 视觉几何

2.5.1 相机模型

世界坐标系：三维空间中的参考坐标系 (U, V, W)

相机坐标系：以相机光心为原点，光轴为 Z 轴，光轴垂直图像平面的三维坐标系 $(X\ Y, Z)$

图像坐标系：二维图像平面上的坐标系 (x, y)，由相机坐标系正交投影得到

像素坐标系：以图像左上角为原点，水平向右为 X 轴，垂直向下为 Y 轴的二维坐标系 (u, v)，由图像坐标系数字化得到

透视矩阵方程：描述三维点 (X, Y, Z) 在图像平面上投影点 (x, y) 的关系

$$\begin{bmatrix} x' \\ y' \\ z' \end{bmatrix} = \begin{bmatrix} f & 0 & 0 & 0 \\ 0 & f & 0 & 0 \\ 0 & 0 & 1 & 0 \end{bmatrix} \begin{bmatrix} X \\ Y \\ Z \\ 1 \end{bmatrix} \tag{56}$$

外参数：世界坐标系到相机坐标系的变换通过旋转矩阵 R 和平移向量 T 实现

$$P_C = R(P_W - C) = RP_W - RC = RP_W + T \tag{57}$$

其中，R 为旋转矩阵，T 为平移矩阵，具体表示为：

$$\begin{bmatrix} X \\ Y \\ Z \\ 1 \end{bmatrix} = \begin{bmatrix} r_{11} & r_{12} & r_{13} & 0 \\ r_{21} & r_{22} & r_{23} & 0 \\ r_{31} & r_{32} & r_{33} & 0 \\ 0 & 0 & 0 & 1 \end{bmatrix} = \begin{bmatrix} 1 & 0 & 0 & -c_x \\ 0 & 1 & 0 & -c_y \\ 0 & 0 & 1 & -c_z \\ 0 & 0 & 0 & 1 \end{bmatrix} \begin{bmatrix} U \\ V \\ W \\ 1 \end{bmatrix} \tag{58}$$

变换矩阵为，称为外参数（R，T）：

$$\begin{bmatrix} r_{11} & r_{12} & r_{13} & t_x \\ r_{21} & r_{22} & r_{23} & t_y \\ r_{31} & r_{32} & r_{33} & t_z \\ 0 & 0 & 0 & 1 \end{bmatrix} = \begin{bmatrix} R & T \\ 0 & 1 \end{bmatrix} \tag{59}$$

内参数：描述相机坐标系到像素坐标系的变换

在相机坐标变换到像素坐标时，存在缩放与坐标原点偏移

$$u = \frac{1}{s_x} f \frac{X}{Z} + o_x \quad v = \frac{1}{s_y} f \frac{Y}{Z} + o_y \tag{60}$$

其中 $\frac{s_y}{s_x}$ 称为长宽比，将内参数加入透视矩阵方程：

$$\begin{bmatrix} x' \\ y' \\ z' \end{bmatrix} = \begin{bmatrix} \frac{f}{s_x} & 0 & o_x & 0 \\ 0 & \frac{f}{s_y} & o_y & 0 \\ 0 & 0 & 1 & 0 \end{bmatrix} \begin{bmatrix} X \\ Y \\ Z \\ 1 \end{bmatrix} \tag{61}$$

化简齐次坐标系可以得到：

$$u = \frac{x'}{z'} \quad v = \frac{y'}{z'} \tag{62}$$

更一般的内参数矩阵表示为：

$$K = \begin{bmatrix} \frac{f}{s_x} & s & o_x & 0 \\ 0 & \frac{f}{s_y} & o_y & 0 \\ 0 & 0 & 1 & 0 \end{bmatrix} = \begin{bmatrix} a_{11} & a_{12} & a_{13} \\ a_{21} & a_{22} & a_{23} \\ 0 & 0 & 1 \end{bmatrix} \begin{bmatrix} f & 0 & 0 & 0 \\ 0 & f & 0 & 0 \\ 0 & 0 & 1 & 0 \end{bmatrix} = M_{aff} M_{proj} \tag{63}$$

其中 s 为倾斜因子

2.5.2 射影几何

定义三维向量 $m_1 = (x_1, y_1, t_1)^T$ 和 $m_2 = (x_2, y_2, t_2)^T$ 的叉积：

$$m_1 \times m_2 = (\det \begin{bmatrix} y_1 & t_1 \\ y_2 & t_2 \end{bmatrix} \det \begin{bmatrix} t_1 & x_1 \\ t_2 & x_2 \end{bmatrix} \det \begin{bmatrix} x_1 & y_1 \\ x_2 & y_2 \end{bmatrix})^T \tag{64}$$

定义反对称矩阵：

$$[m]_\times = \begin{bmatrix} 0 & -t & y \\ t & 0 & -x \\ -y & x & 0 \end{bmatrix} \tag{65}$$

性质：

1. $rank([m]_\times) = 2$，$\forall m \neq 0$
2. $[m]_\times n = m \times n$
3. $[m]_\times m = 0$
4. $m^T [n]_\times m = 0$

无穷远点：同一组平行直线在投影平面上的交点
无穷远直线：同一平面上所有无穷远点的集合
无穷远平面：三维空间内所有无穷远点组成的平面
不全为 0 的 $x_1, \ldots, x_n$ 组成的向量 $(x_1, \ldots, x_n, 0)$ 为无穷远点的齐次坐标表示

由 P_1, P_2 确定的直线上有一点 P 的齐次坐标表示为：

$$P = c_1 P_1 + c_2 P_2 \tag{66}$$

其中 c_1, c_2 不全为 0，$\frac{c_1}{c_2}$ 为 P 关于 P_1, P_2 在直线上的射影参数

交比：在同一直线上取四个不同点 P_1, P_2, P_3, P_4，定义交比为：

$$(P_1, P_2; P_3, P_4) = \frac{(\theta_1 - \theta_3)(\theta_2 - \theta_4)}{(\theta_1 - \theta_4)(\theta_2 - \theta_3)} \tag{67}$$

其中 θ_i 为点 P_i 的射影参数，交比、共点、共线为射影变换的不变量

2.5.3 消隐点与消隐线

消隐点：无穷远点的投影

属性：

1. 任意两条平行直线的消隐点相同
2. 从相机中心出发经过消隐点的射线平行于 1 中的直线
3. 一幅图像中可以有多个消隐点

消隐线：同一平面投影得到的所有消隐点组成的直线（不同平面对应不同消隐线）

对直线 $M = M_0 + Dt$，计算消隐点：

$$M = \begin{bmatrix} M_x + D_x t \\ M_y + D_y t \\ M_z + D_z t \\ 1 \end{bmatrix} = \begin{bmatrix} \frac{M_x}{t} + D_x \\ \frac{M_y}{t} + D_y \\ \frac{M_z}{t} + D_z \\ \frac{1}{t} \end{bmatrix} \xrightarrow[t \to \infty]{} \begin{bmatrix} D_x \\ D_y \\ D_z \\ 0 \end{bmatrix} = M_\infty \tag{68}$$

对平行线 $p_1 q_1, p_2 q_2$ 相交于点 v，计算消隐点：

$$v = (p_1 \times q_1) \times (p_2 \times q_2) \tag{69}$$

多组平行线可以计算出多个消隐点，连接这些消隐点得到消隐线 l_∞

2.5.4 单应矩阵

描述同一平面上两幅图像中对应点之间的映射关系，也可以表示平面物体在图像中的投影变换

对于平面物体，经过外参数矩阵与内参数矩阵变换后得到目标图像，由于平面物体的齐次坐标表示为 $P = (X, Y, 0, 1)^T$，可以将变换矩阵简化为 3x3 矩阵

$$H = \begin{bmatrix} h_{11} & h_{12} & h_{13} \\ h_{21} & h_{22} & h_{23} \\ h_{31} & h_{32} & h_{33} \end{bmatrix} \tag{70}$$

称 H 为单应矩阵，满足关系：

$$s\begin{bmatrix}u\\v\\1\end{bmatrix}=H\begin{bmatrix}X\\Y\\1\end{bmatrix} \tag{71}$$

单应矩阵自由度为 8，只需要 4 对对应点即可求解，对于大于 4 对对应点，可以使用最小二乘法进行估计。

当相机做纯旋转时，由于外参数矩阵中的平移分量为 0，可以直接用单应矩阵表示三维点到图像点的映射关系。

2.5.5 双目立体视觉

简单的双目相机模型：两台相机光轴平行，且在同一平面上，右相机相对左相机仅有一个 x 方向上的平移 T_x

对于图像上左右相机分别得到的点 (x_l, y_l) 和 (x_r, y_r)，有关系：

$$y_l = y_r \quad d = x_l - x_r = T_x\frac{f}{Z} \tag{72}$$

其中 d 为视差，Z 为点到相机的深度距离，f 为相机焦距，由此可得深度与视差成反比

由于两点的 y 坐标相同，只需要在一条线的范围内搜索对应点，称为**极线约束**，极线约束可以大大减少匹配计算量

2.5.6 两视点几何

外极线约束：左图像上的一个点对应右图像上的一条直线，称为极线，右图像上的对应点位于该直线上，因此搜索时只需在该直线上进行

外极几何：

- 基线：连接两相机光心的直线
- 外极点：基线与图像平面的交点
- 外极平面：过基线的平面
- 外极线：外极平面与图像平面的交线

本质矩阵：由相机外参数决定，描述两幅图像中对应点之间的关系

$$E = [T]_\times R \tag{73}$$

其中，$[T]_\times$ 为平移向量 T 的反对称矩阵，R 为旋转矩阵，M 为世界坐标系下的点的齐次坐标表示

对应点满足关系：

$$M_r^T E M_l = 0 \tag{74}$$

由于 $[T]_\times$ 的秩为 2，E 的秩也为 2，且 E 有 5 个自由度（3 个来自 R，2 个来自 T 的方向）

基本矩阵：由相机内外参数共同决定，描述两幅图像中对应点之间的关系

$$F = K_r^{-T} E K_l^{-1} \tag{75}$$

其中，K_l, K_r 分别为左、右相机的内参数矩阵，m 为图像坐标系下的点的齐次坐标表示

对应点满足关系：

$$m_r^T F m_l = 0 \tag{76}$$

F 有 7 个自由度（5 个来自 E，2 个来自内参数的比例因子）

计算方式：八点法

1. 对两幅图像进行归一化变化，将图像中心平移到坐标系原点，缩放使得图像点的平均距离为 $\sqrt{2}$，得到归一化矩阵 H, H'

2. 由 N（N≥8）对对应点 $(u_i, v_i), (u_i', v_i')$，构建矩阵 A：

$$A = \begin{bmatrix} u_1u_1' & u_1v_1' & u_1 & v_1u_1' & v_1v_1' & v_1 & u_1' & v_1' & 1 \\ \cdots & \cdots & \cdots & \cdots & \cdots & \cdots & \cdots & \cdots & \cdots \\ u_Nu_N' & u_Nv_N' & u_N & v_Nu_N' & v_Nv_N' & v_N & u_N' & v_N' & 1 \end{bmatrix} \tag{77}$$

3. 对 A 进行奇异值分解，得到 $A = U\Sigma V^T$，则基本矩阵 F 为 V 的最后一列重构为 3x3 矩阵

4. 强制 F 的秩为 2：对 F 进行奇异值分解，得到 $F = U\Sigma V^T$，将 Σ 的最小奇异值设为 0，重新计算 $\tilde{F} = U\Sigma V^T$

5. 反归一化：$F = H'^T \tilde{F} H$

2.6 三维重建

2.6.1 相机内参数标定

基于三维标定物的相机标定（直接线性变换法 DLT）：

基于三维点与其对应的二维图像点，构建方程组求解相机投影矩阵

1. 收集 N（N≥6）组三维点 (X_i, Y_i, Z_i) 与其对应的二维图像点 (u_i, v_i)

2. 归一化处理：将三维点与二维点分别进行平移与缩放，使得点集的质心位于原点，平均距离为 1，得到归一化矩阵 T_{3D}, T_{2D}

3. 构建二维点与三维点的叉积方程组：

$$m_i \times (PM_i) = 0 \tag{78}$$

其中，$m_i = (u_i, v_i, 1)^T$，$M_i = (X_i, Y_i, Z_i, 1)^T$

4. 将 N 组方程组合成矩阵形式 $Ap = 0$，其中 p 为投影矩阵 P 的 12 个元素组成的向量

5. 将线性解作为初值，优化几何误差，得到最终投影矩阵

6. 去归一化得到内参数与外参数矩阵的乘积 P

7. 使用 RQ 分解得到内参数矩阵 K（上三角）与外参数矩阵 $[R|T]$（正交）

基于二维平面标定物的相机标定（张正友方法）：

使用已知尺寸的棋盘格图案作为标定物，拍摄多张不同角度的图像，通过计算单应矩阵求解内参数与外参数

令 $H = [h_1, h_2, h_3] = K[r_1, r_2, t]$，其中 r_1, r_2 为旋转矩阵的前两列，t 为平移向量

满足关系：

$$r_1^T r_2 = 0 \quad ||r_1|| = ||r_2|| = 1 \tag{79}$$

$$h_1^T K^{-T} K^{-1} h_2 = 0 \quad h_1^T K^{-T} K^{-1} h_1 = h_2^T K^{-T} K^{-1} h_2 \tag{80}$$

每幅图像提供两条约束方程，使用 N（N≥3）幅图像可以构建方程组求解 $B = K^{-T}K^{-1}$

2.6.2 视觉三维重建

通过多幅图像中对应点的几何关系，恢复三维场景的结构

图像 → 稀疏点云 → 稠密点云 → 网格 → 模型

两视角三维重建：

1. 对两张目标图像进行特征点匹配，得到对应点集

2. 基于对应点集计算两相机之间的基本矩阵 F

3. 令第一个相机坐标系作为世界坐标系，则其外参数为 $[I|0]$，通过分解基本矩阵计算第二个相机的外参数 $[R|T]$，可以得到四组解，其中只有一组解满足三维点在两相机前方

4. 对每一对对应点，使用三角测量法计算三维点坐标

多视角三维重建：

直接思路：

1. 分别对相邻图像对进行两视角三维重建，得到多个局部点云
2. 将局部点云进行配准融合，得到全局点云

捆绑调整：

1. 对所有图像进行特征点匹配，得到大规模对应点集
2. 初始化相机内外参数与三维点坐标
3. 构建非线性最小二乘问题，优化相机参数与三维点坐标，使得重投影误差最小
4. 使用稀疏矩阵求解技术提高计算效率

增量式 SfM：给定一组图像，迭代计算场景三维结构

1. 重建初始化：选取种子相机并计算其位姿
2. 增量式重建：不断添加新的相机并反复进行捆绑调整，直至没有新的相机可添加

全局式 SfM：给定一组图像，旨在一次性计算相机位姿以及场景结构

1. 分别计算邻接相机的相对变换关系
2. 旋转平均：一次性计算所有相机的全局姿态（旋转矩阵）
3. 平移平均：一次性计算所有相机的全局位置（差个尺度）
4. 通过捆绑调整，得到最终的相机位姿与场景结构

2.6.3 视觉定位

相机定位：已知环境三维模型与图像，计算相机位姿

n 点透视问题 PnP：已知 n 个三维点与其对应的二维图像点，计算相机的外参数

P3P 问题：已知 3 个三维点与其对应的二维图像点，计算相机的外参数，存在多组解

1. 根据余弦定理可得三个方程：

$$OA^2 + OB^2 - 2(OA)(OB)cos\angle AOB = AB^2 \tag{81}$$

$$OB^2 + OC^2 - 2(OB)(OC)cos\angle BOC = BC^2 \tag{82}$$

$$OA^2 + OC^2 - 2(OA)(OC)cos\angle AOC = AC^2 \tag{83}$$

其中 $\angle AOB, \angle BOC, \angle AOC$ 为相机光心与三维点构成的夹角，可由相机内参数与二维图像点计算得到

2. 三个公式同时除以 OC^2，令 $x=\frac{OA}{OC}, y=\frac{OB}{OC}$，得到三个关于 x,y 的二次方程

3. 令 $v=\frac{AB^2}{OC^2}, u=\frac{BC^2}{AB^2}, w=\frac{CA^2}{AB^2}$，得到：

$$f_1 : x^2+y^2-2xycos\angle AOB=v \tag{84}$$

$$f_2 : y^2+1-2ycos\angle BOC=uv \tag{85}$$

$$f_3 : x^2+1-2xcos\angle AOC=wv \tag{86}$$

可以化简为两个关于 x,y 的二次方程

4. 根据上述方程可以计算得到变换关系

直接线性变换法 DLT：已知 n（n≥6）个三维点与其对应的二维图像点，构建方程组求解相机外参数

1. 直接根据投影公式，忽略旋转矩阵 3 个自由度的约束，将外参数矩阵视为一个 3x4 矩阵

2. 展开后可以得到每对 2D-3D 对应点提供两个线性方程

3. 使用 N（N≥6）对对应点构建方程组 $Ap=0$，其中 p 为外参数矩阵的 12 个元素组成的向量

4. 得到的旋转矩阵一般不满足旋转矩阵的约束，需要进一步近似

5. 对得到的旋转矩阵进行奇异值分解 $R=U\Sigma V^T$，若 $det(UV^T)>0$，则 $R=UV^T$，否则 $R=Udiag(1,1,-1)V^T$

在线定位：

数据关联：空间点与图像点、图像点与图像点、空间点与空间点之间的关联。

闭环检测：移动载体自动检测其运行轨迹中出现的闭环，进而基于闭环约束缓解累计误差，对先前定位结果进行修正。

重定位：系统运行失败后自动恢复自身定位功能。

基于滤波器的实时定位方法：将相机位置、姿态与地图特征等未知信息作为滤波器的状态量，利用相机的观测特征不断地估计相机位置、姿态与地图特征。常用卡尔曼滤波器、粒子滤波器等。

基于几何的实时定位方法：基于关键帧，确定相机位姿，利用几何重建创建环境地图，利用图像信息与地图信息实时计算相机的位置姿态。

目标定位：识别输入图像中的特定物体实例，并确定每个物体相对于相机坐标系的位置与方向。可分为实例级物体姿态估计（训练和测试时针对同一物体实例）与类别级物体姿态估计。

基于模板匹配的方法：首先生成物体的姿态码本，该码本包含物体每个姿态的中间表示。在推理过程中，提取输入图像的中间表示，返回码本中与最佳匹配模板对应的 6D 姿态。

直接法：使用姿态估计网路直接从输入图像中预测 6D 物体姿态。

- 3D 平移估计：根据语义标签对每个物体像素的中心方向 X、Y 投票，得到物体在图像上的中心坐标。通过对该中心坐标反向投影得到物体中心的 3D 坐标，即物体相对于相机的平移。

- 3D 旋转回归：通过对旋转的四元数进行回归，得到物体相对于相机的旋转。

$$q = (q_0, q_1, q_2, q_3)^T \quad ||q|| = 1 \tag{87}$$

$$R = \begin{bmatrix} 1-2(q_2^2+q_3^2) & 2(q_1q_2-q_0q_3) & 2(q_1q_3+q_0q_2) \\ 2(q_1q_2+q_0q_3) & 1-2(q_1^2+q_3^2) & 2(q_2q_3-q_0q_1) \\ 2(q_1q_3-q_0q_2) & 2(q_2q_3+q_0q_1) & 1-2(q_1^2+q_2^2) \end{bmatrix} \tag{88}$$

不足：CNN 难以从训练数据中学习物体姿态相关的所有几何知识。

基于 PnP 的方法：估计图像像素到物体模型点的 2D-3D 对应，进而求解 PnP 问题计算物体的姿态。根据得到的对应点数量可以分为基于关键点与基于稠密对应的方法。

基于关键点的方法：使用如 SIFT、ORB 等特征提取模块来检索图像中的二维关键点，并将其与物体模型中的三维关键点进行匹配，得到 2D-3D 对应点集，进而使用 PnP 方法估计物体姿态。

基于稠密对应的方法：使用神经网络估计图像中每个点对应的三维坐标，从而建立稠密的 2D-3D 对应关系，进而使用 PnP 方法估计物体姿态。

2.7 目标跟踪与行为识别

2.7.1 目标跟踪

运动目标的表示方式分为：基于点、区域、轮廓、模型的跟踪。

基于点的跟踪可以用目标的质心或一组特征点集，或运动轮廓的角点等表示目标位置。

基于区域的跟踪将运动目标用较为简单的几何形状表示（矩形、椭圆等），适合用于表示简单的刚体或非刚体运动目标，但精度较差。

基于轮廓的跟踪使用封闭的曲线轮廓表示目标位置，适合用于表示复杂形状的目标。

基于模型的跟踪使用二维形状模型或三维模型表示目标位置，适合用于表示复杂形状的目标。

目标跟踪的两种处理思路：

- 自底向上（模板匹配）：数据驱动，不依赖于先验知识。
- 自顶向下（卡尔曼滤波器）：模型驱动，依赖于所构建的模型或先验知识。

模板匹配：

前一帧图像中目标（模板）位置为 (x, y)，在当前帧搜索位置 $(x', y') = (x+dx, y+dy)$，使得 $argmax_{dx,dy} cov(T(x, y), I(x', y'))$

概念上较为简单，穷举搜索计算量大。

卡尔曼滤波器：

动态系统由状态转移方程与观测方程描述：

$$x_k = f(x_{k-1}, w_{k-1}) \tag{89}$$

$$y_k = h(x_k, v_k) \tag{90}$$

其中，x_k 为时刻 k 的状态向量，y_k 为时刻 k 的观测向量，w_{k-1} 为系统噪声，v_k 为测量噪声，f, h 在多数跟踪问题中非线性。

基本假设：

- 后验概率分布 $p(x_{k-1}|y_{1:k-1})$ 为高斯分布。
- 动态系统线性：$x_k = Ax_{k-1} + Bu_{k-1} + w_{k-1} \quad y_k = Hx_k + v_k$，其中 u_k 为控制向量，由外部输入决定。
- 系统噪声与测量噪声服从高斯分布，协方差矩阵分别为 Q 和 R。

迭代更新：

- 时间更新：

$$\hat{x}_k^- = A\hat{x}_{k-1} + Bu_{k-1} \tag{91}$$

$$P_k^- = AP_{k-1}A^T + Q \tag{92}$$

- 状态更新：

$$K_k = P_k^- H^T (HP_k^- H^T + R)^{-1} \tag{93}$$

$$\hat{x}_k = \hat{x}_k^- + K_k(y_k - H\hat{x}_k^-) \tag{94}$$

$$P_k = (I - K_k H)P_k^- \tag{95}$$

相关滤波与跟踪（MOSSE）：在视频帧中找到与相关核响应最高的位置，实现跟踪，但是速度较慢。

基于深度网络的方法：全卷积神经网络（FCN）用于目标跟踪，本质上是将 VGG 网络的全连接层替换为卷积层，实现端到端的目标跟踪。

2.7.2 行为识别

行为识别可以视为时变特征数据的分类问题，即将待识别的行为序列（测试序列）与预先标记好的代表典型行为的参考序列进行匹配。由于人动作执行的差异，匹配行为序列时必须能够处理相似运动模式在空间和时间尺度上轻微的特征变化。

基于模板匹配的方法：通过计算测试序列与参考序列之间的相似度来识别行为类别。

运动能量图：通过帧间差分得到前景的二值化图像后将所有前景的二值化图像取并集。

$$E_\tau(x,y,t)=\bigcup_{i=0}^{\tau}D(x,y,t-i) \tag{96}$$

其中，$D(x,y,t)$ 为时刻 t 的二值化前景图像，τ 为一个动作的运动时间。

运动能量图对于结构不同的动作序列容易产生混淆，引入运动历史图：

$$H_\tau(x,y,t)=\begin{cases}\tau, & D(x,y,t)=1\\ \max(0,H_\tau(x,y,t-1)-1), & D(x,y,t)=0\end{cases} \tag{97}$$

在运动历史图上，越接近当前帧的运动像素越明亮。

在图像上提取基于不变矩的运动特征（具有平移、旋转和尺度不变性），采用马氏距离度量测试序列与模板的相似度。

Hu 矩：

$$m_{pq}=\int_{-\infty}^{\infty}\int_{-\infty}^{\infty}x^p y^q\rho(x,y)\,dx\,dy \tag{98}$$

$$\mu_{pq}=\int_{-\infty}^{\infty}\int_{-\infty}^{\infty}(x-\bar{x})^p(y-\bar{y})^q\rho(x,y)\,d(x-\bar{x})\,d(y-\bar{y}) \tag{99}$$

$$\bar{x}=\frac{m_{10}}{m_{00}}\quad \bar{y}=\frac{m_{01}}{m_{00}} \tag{100}$$

$$\eta_{pq}=\frac{\mu_{pq}}{\mu_{00}^{\gamma}}\quad \gamma=\frac{p+q}{2}+1\quad p+q\geq 2 \tag{101}$$

式（98）为 $(p+q)$ 阶矩，式（99）为中心矩，式（101）为归一化中心矩。

七个不变矩：

$$\nu_1=\eta_{20}+\eta_{02} \tag{102}$$

$$\nu_2=(\eta_{20}-\eta_{02})^2+4\eta_{11}^2 \tag{103}$$

$$\nu_3=(\eta_{30}-3\eta_{12})^2+(3\eta_{21}-\eta_{03})^2 \tag{104}$$

$$\nu_4=(\eta_{30}+\eta_{12})^2+(\eta_{21}+\eta_{03})^2 \tag{105}$$

$$\nu_5=(\eta_{30}-3\eta_{12})(\eta_{30}+\eta_{12})[(\eta_{30}+\eta_{12})^2-3(\eta_{21}+\eta_{03})^2]+(3\eta_{21}-\eta_{03})(\eta_{21}+\eta_{03})[3(\eta_{30}+\eta_{12})^2-(\eta_{21}+\eta_{03})^2] \tag{106}$$

$$\nu_6=(\eta_{20}-\eta_{02})[(\eta_{30}+\eta_{12})^2-(\eta_{21}+\eta_{03})^2]+4\eta_{11}(\eta_{30}+\eta_{12})(\eta_{21}+\eta_{03}) \tag{107}$$

$$\nu_7 = (3\eta_{21}-\eta_{03})(\eta_{30}+\eta_{12})[(\eta_{30}+\eta_{12})^2-3(\eta_{21}+\eta_{03})^2]-(\eta_{30}-3\eta_{12})(\eta_{21}+\eta_{03})[3(\eta_{30}+\eta_{12})^2-(\eta_{21}+\eta_{03})^2] \tag{108}$$

基于状态转移图的方法：定义每个静态姿势为一个状态，这些状态之间通过某种概率联系。任何运动序列可以视为静态姿势的不同状态之间的一次遍历过程，计算遍历的联合概率，选择最大值作为分类行为的标准。

HMM 的三个问题：

- 估值问题：给定一组模型参数 λ，一组观测序列 O，计算 $P(O|\lambda)$。

  前向算法：

  1. 初始化：

  $$\alpha_1(i) = \pi_i b_i(o_1) \quad 1 \le i \le N \tag{109}$$

  2. 迭代：

  $$\alpha_{t+1}(j) = \left[\sum_{i=1}^{N} \alpha_t(i)a_{ij}\right] b_j(o_{t+1}) \quad 1 \le j \le N, 1 \le t \le T-1 \tag{110}$$

  3. 终止：

  $$P(O|\lambda) = \sum_{i=1}^{N} \alpha_T(i) \tag{111}$$

  后向算法：

  1. 初始化：

  $$\beta_T(i) = 1 \quad 1 \le i \le N \tag{112}$$

  2. 迭代：

  $$\beta_t(i) = \sum_{j=1}^{N} a_{ij} b_j(o_{t+1}) \beta_{t+1}(j) \quad 1 \le i \le N, t = T-1, T-2, \ldots, 1 \tag{113}$$

  3. 终止：

  $$P(O|\lambda) = \sum_{i=1}^{N} \beta_1(i) \tag{114}$$

- 解码问题：给定一组模型参数 λ，一组观测序列 O，寻找最可能的状态序列 Q。

  Viterbi 算法：

  1. 初始化：

  $$\delta_1(i) = \pi_i b_i(o_1) \quad \phi_1(i) = 0 \quad 1 \le i \le N \tag{115}$$

  2. 迭代：

  $$\delta_t(j) = \max_{1 \le i \le N} [\delta_{t-1}(i)a_{ij}] b_j(o_t) \quad 2 \le t \le T, 1 \le j \le N \tag{116}$$

  $$\phi_t(j) = \arg\max_{1 \le i \le N} [\delta_{t-1}(i)a_{ij}] \quad 2 \le t \le T, 1 \le j \le N \tag{117}$$

3. 终止：

$$P^* = \max_{1\le i\le N} \delta_T(i) \quad q_T^* = \arg\max_{1\le i\le N} \delta_T(i) \tag{118}$$

4. 路径回溯：

$$q_t^* = \phi_{t+1}(q_{t+1}^*) \quad t = T-1, T-2, \ldots, 1 \tag{119}$$

- 学习问题：给定训练样本的集合 O，训练模型参数 λ，使得 $P(O|\lambda)$ 最大。

基于深度网络的方法：

RNN：使用 RNN 处理时序数据，每次传入一个时间步的数据，隐状态包含了之前时间步的信息，适合处理变长序列。

LSTM：为了解决 RNN 的梯度消失问题，引入了门控机制，包括输入门、遗忘门和输出门，能够更好地捕捉长时间依赖关系。